

Salma BENSMAIL

Université de Perpignan Via Domitia (UPVD)
Master 2 CHPS
`salma.bensmail@etudiant.univ-perp.fr`

Janvier 2026

- ① Contexte & données (GTSRB)
- ② Méthodologie (prétraitement)
- ③ Architecture CNN légère
- ④ Entraînement
- ⑤ Résultats & analyse d'erreurs
- ⑥ Conclusion & perspectives

Objectif

Concevoir un modèle compact capable de reconnaître 43 classes de panneaux, avec une inférence rapide et une bonne robustesse en conditions réalistes.

1. Contexte & Données

Dataset GTSRB (rappel)

Caractéristiques

- 43 classes de panneaux (vitesse, interdiction, danger, etc.).
- Images RGB de petite taille, avec des conditions de prise de vue variées.
- Découpage train/validation/test selon la configuration expérimentale.

Pourquoi un modèle léger ?

- Déploiement embarqué (véhicule, mobile) et latence faible.
- Réduction mémoire et consommation énergétique.

2. Méthodologie


Prétraitement et augmentation

Prétraitement

- Normalisation des pixels (division par 255).
- Option : amélioration du contraste (ex. CLAHE) selon le pipeline.
- Découpage train/validation stratifié.

Data augmentation

- Petites rotations ($\pm 10^\circ$), zoom léger, flips (si pertinent).
- Objectif : améliorer la généralisation et limiter l'overfitting.



3. Architecture du modèle

Architecture : CNN léger

Idée générale

Le réseau extrait des caractéristiques visuelles (formes, contours), puis réalise une classification parmi 43 classes.

Composants


- Convolutions : extraction de motifs (features).
- Pooling : réduction de dimension et accélération.
- Couche finale (Softmax) : décision de classe.

Pourquoi "léger" ?

Moins de paramètres $\Rightarrow$ modèle plus rapide et plus simple à déployer sur système embarqué.

Schéma du pipeline CNN (illustration)

Architecture du réseau de neurones convolutionnel (CNN) pour la reconnaissance des panneaux de signalisation (GTSRB)



Convolutions → extraction de caractéristiques → classification.

4. Entraînement

Configuration d'entraînement

Paramètre	Valeur
Optimiseur	Adam (lr=0.001)
Fonction de perte	Categorical Crossentropy
Batch size	128
Époques	Selon early stopping / convergence
Métrique	Accuracy (taux de bonne classification)
Plateforme	GPU (Google Colab)


Remarque

Les hyperparamètres (scheduler, ReduceLROnPlateau, early stopping) peuvent être ajustés pour stabiliser la validation.


5. Résultats & Analyse

Courbes d'apprentissage

Courbes de Loss



Courbes d'Accuracy



Ce qu'on observe

- Début : perte élevée, amélioration rapide.
- Milieu : baisse nette de la perte, hausse de l'accuracy.
- Fin : stabilisation, le gain devient marginal.
- Écart train/validation limité : généralisation correcte (overfitting réduit).

Résultats sur la matrice de confusion

Comment la lire ?


- Axe horizontal : classe prédite ; axe vertical : vraie classe.
- Diagonale : bonnes prédictions (vrai = prédit).
- Hors diagonale : confusions entre classes.

Ce qu'on observe ici

- Diagonale marquée : bonne performance globale sur la majorité des classes.
- Peu de valeurs hors diagonale : erreurs globalement rares.
- Confusions localisées (proches de la diagonale) : classes visuellement similaires / images dégradées.

Analyse

Les erreurs ne sont pas aléatoires : elles se concentrent sur quelques paires de classes, ce qui est cohérent avec la similarité visuelle et la variabilité des conditions d'acquisition.



Matrice de confusion (GTSRB, 43 classes)

Analyse qualitative des prédictions

Exemples bien classés

Exemples de panneaux bien classés



Prediction cohérente avec la vérité terrain

Exemples en erreur

Exemples de panneaux mal classés



Confusions entre classes proches

Cas d'étude : prédiction haute confiance (panneau 31)

Vrai: 31 | Prédit: 31 | Confiance: 0.998



Résultats de prédiction

- Vraie classe : 31
- Classe prédite : 31
- Confiance : 99.8%

Interprétation

Le modèle prédit avec certitude ce panneau de limite de vitesse "70" (classe 31).

Raisons du succès :

- Caractéristiques visuelles claires et bien préservées.
- Motifs distinctifs : bordure rouge, fond blanc, chiffre noir net.
- Pas d'occlusion, éclairage convenable, orientation correcte.

Conclusion

Cette prédiction illustre le bon apprentissage du modèle sur les panneaux avec des caractéristiques distinctives et des conditions d'acquisition favorables.

Analyse : distribution de confiance et robustesse

Qu'est-ce que la confiance ?

La confiance est la probabilité attribuée à la classe prédite par le modèle (sortie Softmax).

$$\text{Confiance} = \max(\text{Softmax}(\text{logits}))$$

Observations clés

- 99.8% = très haute confiance.
- Indique que le réseau a appris à bien séparer cette classe des autres.
- Les activations internes sont très discriminantes.

Points d'attention

Confiance élevée toujours correcte. En adversarial ou conditions dégradées, même haute confiance peut être trompeuse.

Statistiques de confiance globales

Basées sur les résultats de test :

- **Confiance moyenne** : $\approx 95\%$
Bon signe de calibration
- **Confiance min (erreurs)** : $\approx 45\%$
Modèle "hésite" sur les cas difficiles
- **Confiance max (correctes)** : $\approx 99.9\%$
Très sûr pour les cas faciles

Implication

Distribution normale : le modèle discrimine bien entre certitude et doute.

Conclusion & perspectives

Bilan

- Modèle CNN léger pour une classification multi-classes (43 panneaux).
- Bon comportement d'apprentissage (courbes train/validation cohérentes).
- Erreurs principalement concentrées sur des classes proches visuellement.
- Prédictions haute confiance sur panneaux avec caractéristiques distinctives.

Perspectives

- Quantification (TFLite / INT8) : réduire taille mémoire et latence.
- Augmentations plus réalistes (flou, pluie, occultations) : robustesse.
- Ajouter une détection (YOLO/SSD) : pipeline ADAS complet.
- Calibration de confiance : mieux estimer l'incertitude en conditions réelles.

Merci !

Des questions ?

`salma.bensmail@etudiant.univ-perp.fr`